

Использование ассемблерных вставок в «Си» коде Hash table.

А.А. Хромов

30 апреля 2018 г.

Содержание

1	Цель работы и материалы.	3
2	Теоретическая часть	3
3	Ход работы	5
3.1	Написание кода программы	5
3.2	Написание кода программы ещё раз и правильно	5
3.3	Сон	5
3.4	Написание кода- что бы уже работал прям точно	5
4	Вывод.	8

1 Цель работы и материалы.

Цель работы: написание эффективного кода, использующий хеш-таблицы в работе со строками.

В работе используются: Xcode.

2 Теоретическая часть

В нашей программе будет использоваться 6 хеш-функций с номерами от 0 до 5:

```
1 unsigned int Hash0 (char* str) {
2     return (int)(str [0]);
3 }
```

Первая функция будет возвращать код первого символа в слове.

```
1 unsigned int Hash1 (char* str) {
2     return 1;
3 }
```

Вторая функция будет на любую строку возвращать 1.

```
1 unsigned int Hash2 (char* str) {
2     return strlen(str);
3 }
```

★Ну тут я считаю нужно крч задокументировать, что эта делает: так как даже мне не очевидно. Оказывается «strlen» (есть оказывается такая функция, где-то в далеких стандартах «Си», поэтому вы не пугайтесь) она, не буду тянуть, в общем, возвращает длину массива (в чарках).★

```
1 unsigned int Hash3 (char* str)
2     int sum = 0;
3     for (int i = 0; str [i] != 0; sum += str [i], i++)
4         return sum;
5
```

Этот хеш суммирует все коды символов строки и возвращает её.

```
1 unsigned int Hash4 (char* str) {
2     int h = 0;
3     for (int i = 0; str [i] != 0; h = ((h << 5) + h) + str [i], i++) {}
4     return h;
5 }
```

GNU хеш, это вам не стрлен, тут все кристально понятно, если нет, то рекомендую ознакомиться с этим докладом позже, так как он может показаться вам сложными и не своевременным (замете, что «тупым» я вас не называл (вы сами это сделали в своей голове (мяу))).

```
1 unsigned int Hash5 (char* str) {
2     unsigned int h = 0;
3
4     for (int i = 0; str [i] != 0; i++) {
5         h = frol(h, 1) ^ str [i];
6     }
7     return h;
8 }
9
10 int frol (int n, int len) //ROL
11 {
12     if ((n % 2) == 1)
13     {
14         return ((n << len) | 0x80);
15     }
16     return n << len;
17 }
```

Циклический сдвиг.

Далее было бы целесообразно, рассказать некоторый «геометрический» смысл важных для нас функций, которые участвуют в программе. Сам код будет выделен в приложении, или его можно будет найти в прикладываемом файле (А вообще вам должны были рассказать об этом на лекции и показать на семинаре, но если нет, то об этом очень внятно и коротко написано в «кириченко», но лучше прочтите об этом в «Сивухине» (Мяу)).

И первое, нет это не мейн)), это функция

```
CraftString (list<char*>* array, int* size, unsigned int
(*Hash)(char*), int text_length, char* buf, const char*
name_files);
```

Она обрабатывает буфер «char* buf», выделяет из него строку, и работает с ней по функции «unsigned int (*Hash)(char*)», заполняя хеш-таблицу «list<char*>* array», которую потом выводит в файл с именем

«const char* name_files»

Сама функция в работе со словом ссылается на другую функцию:

```
int TablFind (list<char*>* array, char* str, int* size,  
unsigned int (*Hash)(char*));
```

Она получает слово «char* str», и отдает его уже в «unsigned int (*Hash)(char*)», после обрабатывает и заполняет хеш-таблицу «list<char*>* array» размера «int* size».

На этом мы можем закончить поверхностное изучение основного кода, но хотелось бы так же заметить одну деталь, на которую мог обратить своё внимание "невнимательный" читатель. Мы использовали в работе свой класс «list» и о его устройстве тут, конечно же, рассказываться не будет, так как это выходит за рамки изучения аспекта проблемы (мне тупо лень Карл), о нем можно будет подробно узнать в приложении или в прилегающем файле.

3 Ход работы

3.1 Написание кода программы

В работе нон-стоп пишем радостно код и параллельно смотрим сериальчик, отвлекаясь на херстоун.

Пытаемся запустить код, а потом ещё раз и ещё. Удивительно, но факт: **ОН НЕ РАБОТАЕТ!!!**

3.2 Написание кода программы ещё раз и правильно

Тут совет от опытных пацанов с района: попробуйте выключить хотя бы игру, если результат повторится, то нужно будет так же выключить и сериальчек перед написанием кода.

3.3 Сон

Сон, а то вставать уже через 2 часа.

3.4 Написание кода- что бы уже работал прям точно

Ну вот, уже полдела сделано, можно показывать препу и поднять авторитет, что бы удос нам был прям обеспечен, но мы не станем. Давай те

лучше вспомним цель нашей работы: «Написание эффективного кода...». Прогоним наш код через профайл, и и снимем данные.

Weight	Self Weight	Symbol Name
15.00 ms	100.0%	▼Hash (21066)
15.00 ms	100.0%	▼Main Thread 0x1c70ad
8.00 ms	53.3%	▼start libdyld.dylib
8.00 ms	53.3%	▼main Hash
7.00 ms	46.6%	▼CraftString(list<char*>*, int*, unsigned int (*)(char*), int, char*, char const*) Hash
4.00 ms	26.6%	►TablFind(list<char*>*, char*, int*, unsigned int (*)(char*)) Hash
2.00 ms	13.3%	►PrintFiles(char const*, list<char*>*, int*) Hash
1.00 ms	6.6%	►tolower(int) Hash
1.00 ms	6.6%	►Clear(list<char*>*, int) Hash
7.00 ms	46.6%	►_dyld_start dyld

Рис. 1: результаты profile для кода без асм. вставок.

Мы видим, что функции «TablFind» и «PrintFiles» "жрут" больше всего времени на выполнение. Рассмотрим вначале на вторую из них.

Weight	Self Weight	Symbol Name
15.00 ms	100.0%	▼Hash (21066)
15.00 ms	100.0%	▼Main Thread 0x1c70ad
8.00 ms	53.3%	▼start libdyld.dylib
8.00 ms	53.3%	▼main Hash
7.00 ms	46.6%	▼CraftString(list<char*>*, int*, unsigned int (*)(char*), int, char*, char const*) Hash
4.00 ms	26.6%	►TablFind(list<char*>*, char*, int*, unsigned int (*)(char*)) Hash
2.00 ms	13.3%	▼PrintFiles(char const*, list<char*>*, int*) Hash
1.00 ms	6.6%	►fopen libsystem_c.dylib
1.00 ms	6.6%	►fclose libsystem_c.dylib
1.00 ms	6.6%	►tolower(int) Hash
1.00 ms	6.6%	►Clear(list<char*>*, int) Hash
7.00 ms	46.6%	►_dyld_start dyld

Рис. 2: результаты profile для кода без асм. вставок.

И наблюдаем картину выполнения двух других функций «fopen», «fclose». Данные функции работают с файлами в которые записывают наши хеши. Работа с файлами всегда занимает много времени у процессора, поэтому оптимизировать эту область кода мы не можем.

Рассмотрим тогда первую функцию «TablFind».

Time Profiler > Profile > Root			
Weight	Self Weight	Symbol Name	
15.00 ms 100.0%	0 s	▼Hash (21066)	
15.00 ms 100.0%	0 s	▼Main Thread 0x1c70ad	
8.00 ms 53.3%	0 s	▼start libdyld.dylib	
8.00 ms 53.3%	0 s	▼main Hash	
7.00 ms 46.6%	0 s	▼CraftString(list<char*>*, int*, unsigned int (*)(char*), int, char*, char const*) Hash	
4.00 ms 26.6%	0 s	▼TblFind(list<char*>*, char*, int*, unsigned int (*)(char*)) Hash	
4.00 ms 26.6%	2.00 ms	►strcheck(char*, cell_t<char*>*, int) Hash	
2.00 ms 13.3%	0 s	►PrintFiles(char const*, list<char*>*, int*) Hash	
1.00 ms 6.6%	1.00 ms	►tolower(int) Hash	
1.00 ms 6.6%	0 s	►Clear(list<char*>*, int) Hash	
7.00 ms 46.6%	0 s	►_dyld_start dyld	

Рис. 3: результаты profile для кода без асм. вставок.

Функция «strcheck» работает со строками, использует для этого команду `strcmp`. Предположив, что наш код мог бы обойтись без этой функции, он бы стал куда быстрее. Решим нашу проблему так же, как решали их наши деды. Вспомним язык древних канонов, язык высших созданий-машин, а именно несокрушимый и вечный **АСЕМБЛЕР!!!**

```

1 bool strcheck(char* arg1, cell_t<char*>* cell, int size) {
2     int flag = 0;
3     for (int j = 0; cell != nullptr; j++) {
4
5         flag = 0;
6         __asm__ ("xor %%rax, %%rax                nt"
7                 "L1:                               n"
8                 "lodsb                             nt"
9                 "test %%al, %%al                   nt"
10                "jz EQU                             nt"
11                "xorb (%%rdi), %%al                 nt"
12                "jnz EXIT                           nt"
13                "inc %%rdi                          nt"
14                "jmp L1                             nt"
15                "EQU:                               n"
16                "xorb (%%rdi), %%al                 nt"
17                "EXIT:                              n"
18                "mov %%eax, %[x]                    nt"
19                "nt"
20                : [x] "=r" (flag)
21                : [a] "S" (arg1), [b] "D" (cell->_data)
22                :
23                );

```

```

24     if (flag == 0)
25         return false;
26     cell = cell->_next;
27 }
28
29 return true;
30}

```

Команда «lodsб» загрузить строковый операнд в AL.

Теперь наш код делает тоже самое, что и strcmp, но делает это намного быстрее, так как здесь отсутствует множество промежуточных операций с памятью, которые создаёт компилятор при работе с первоначальной функции.

Давайте прогоним код через «profile»:

Time Profiler > Profile > Root			
Weight	Self Weight	Symbol Name	
16.00 ms	100.0%	0 s	▼ Hash (21142)
16.00 ms	100.0%	0 s	▼ Main Thread 0x1c8376
9.00 ms	56.2%	0 s	▼ start libdyld.dylib
9.00 ms	56.2%	0 s	▼ main Hash
8.00 ms	50.0%	1.00 ms	▼ CraftString(list<char*>*, int*, unsigned int (*)(char*), int, char*, char const*) Hash
5.00 ms	31.2%	1.00 ms	▼ Hash
3.00 ms	18.7%	3.00 ms	▼ TabFind(list<char*>*, char*, int*, unsigned int (*)(char*)) Hash
1.00 ms	6.2%	1.00 ms	EXIT Hash
2.00 ms	12.5%	0 s	strcheck(char*, cell_t<char*>*, int) Hash
1.00 ms	6.2%	0 s	► PrintFiles(char const*, list<char*>*, int*) Hash
7.00 ms	43.7%	0 s	► list<char*>::~~list() Hash
			► _dyld_start dyld

Рис. 4: результаты profile для кода с асм. вставками.

Результат на лицо, с 26% до 6% использования времени. В 4 раза сокращения времени спользование функции.

4 Вывод.

Мы написали эффективный код, использующий хеш-тыблицы в работе со строками, с помощью ассемблерных вставок, что дало спад использованного времени в 4 раза $\pm \epsilon$.